

Projet Image/ML Style Transfer

Donovann Zassot
Tom Zinck

Table des matières

01. Rappel du projet

02. Méthode classique

03. Spécialisation avec un GAN

04. Méthode avancée (StarGan)

05. Ce qu'il reste à faire

Rappels

Qu'est-ce que le transfert de style ?

- Une image d'entrée (dite "*content*")
- Une image source (dite "*style*")

Objectif en sortie :
Image d'entrée dans le style de l'image source

Rappels

1. On récupère nos deux images.
2. On utilise un modèle pré-entraîné (généralement un réseau neuronal convolutif).
3. On extrait les caractéristiques des deux images : ce qu'on veut garder (contenu) et ce qu'on veut copier (style).

Rappels

4. On calcule la différence entre l'image générée et les deux images (contenu et style).
5. On optimise l'image générée pour qu'elle combine le contenu de l'une et le style de l'autre.

On répète 4 et 5 jusqu'à ce que l'image finale soit satisfaisante.

Certaines méthodes plus avancées passent par des modèles de diffusion ou des transformers

Méthode classique

- Première utilisation du deep learning pour faire du transfert de style :
"A Neural algorithm of Artistic Style", Gatys, Ecker & Bethge, 2015

A



B



Méthode classique

- Se base sur le modèle convolutif VGG-19, entraîné sur ImageNet
- Trouver l'image qui minimise une distance au style et au contenu original (gram matrix)
- Pour l'instant, distances utilisent la matrice d'entropie croisée. Trouve d'autres méthodes?



Méthode classique

Limitation : **pas de cohérence locale, pas de notion d'objets. D'avantage un "post-process" qu'une transformation des sujets.**



Méthode classique + GAN

- Idée : Finetune VGG-19 pour le rendre plus efficace sur un style précis
- Création d'un GAN, avec un discriminateur convolutif + optimiser ADAM
- On a des résultats, mais pas encore de comparaison vs non-finetuned

Exemple de test : 20 epoch de 100 images sur jeu d'iconographies chrétiennes




Stargan

Generator (G) prend en entrée :

- une image x (source)
- un code de style s ,

-> produit une image $G(x, s)$ dans le domaine cible.




Stargan

Pour obtenir le code de style s :


- Mapping network (F)
- Style encoder (E)

Le mapping network est là pour injecter de la diversité.



Stargan

Discriminateur (D) prend une image et doit déterminer si elle est réelle ou générée



Le dataset : CelebA-HQ





Ce qu'il reste à faire

- Tester davantage de fonctions de pertes
- Comparatif des méthodes (notamment VGG-19 avec/sans GAN)
- Interface graphique basique mais fonctionnelle (Web app locale)
- Trouver des métriques pour évaluer nos résultats

Des questions ?

Annexe

A decorative line consisting of a horizontal segment at the bottom, a diagonal segment on the right side, and a vertical segment at the top right corner.

LAYER	RESAMPLE	NORM	OUTPUT SHAPE
Image $\mathbf{x}$	-	-	$256 \times 256 \times 3$
Conv 1×1	-	-	$256 \times 256 \times 64$
ResBlk	AvgPool	IN	$128 \times 128 \times 128$
ResBlk	AvgPool	IN	$64 \times 64 \times 256$
ResBlk	AvgPool	IN	$32 \times 32 \times 512$
ResBlk	AvgPool	IN	$16 \times 16 \times 512$
ResBlk	-	IN	$16 \times 16 \times 512$
ResBlk	-	IN	$16 \times 16 \times 512$
ResBlk	-	AdaIN	$16 \times 16 \times 512$
ResBlk	-	AdaIN	$16 \times 16 \times 512$
ResBlk	Upsample	AdaIN	$32 \times 32 \times 512$
ResBlk	Upsample	AdaIN	$64 \times 64 \times 256$
ResBlk	Upsample	AdaIN	$128 \times 128 \times 128$
ResBlk	Upsample	AdaIN	$256 \times 256 \times 64$
Conv 1×1	-	-	$256 \times 256 \times 3$

Table 5. Generator architecture.

TYPE	LAYER	ACTVATION	OUTPUT SHAPE
Shared	Latent $\mathbf{z}$	-	16
Shared	Linear	ReLU	512
Shared	Linear	ReLU	512
Shared	Linear	ReLU	512
Shared	Linear	ReLU	512
Unshared	Linear	ReLU	512
Unshared	Linear	ReLU	512
Unshared	Linear	ReLU	512
Unshared	Linear	-	64

Table 6. Mapping network architecture.

LAYER	RESAMPLE	NORM	OUTPUT SHAPE
Image $\mathbf{x}$	-	-	$256 \times 256 \times 3$
Conv 1×1	-	-	$256 \times 256 \times 64$
ResBlk	AvgPool	-	$128 \times 128 \times 128$
ResBlk	AvgPool	-	$64 \times 64 \times 256$
ResBlk	AvgPool	-	$32 \times 32 \times 512$
ResBlk	AvgPool	-	$16 \times 16 \times 512$
ResBlk	AvgPool	-	$8 \times 8 \times 512$
ResBlk	AvgPool	-	$4 \times 4 \times 512$
LReLU	-	-	$4 \times 4 \times 512$
Conv 4×4	-	-	$1 \times 1 \times 512$
LReLU	-	-	$1 \times 1 \times 512$
Reshape	-	-	512
Linear $\star \mathbb{K}$	-	-	$\mathbb{D} \star \mathbb{K}$

Table 7. Style encoder and discriminator architectures. $\mathbb{D}$ and $\mathbb{K}$ represent the output dimension and number of domains, respectively.